

**МИНОБРНАУКИ РОССИИ**  
**САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ**  
**ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ**  
**«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)**  
**Кафедра математического обеспечения и применения ЭВМ**

**ОТЧЕТ**  
**по лабораторной работе №2**  
**по дисциплине «Статистические методы обработки экспериментальных**  
**данных»**  
**Тема: Обработка выборочных данных. Нахождение точечных оценок па-**  
**раметров распределения.**

Студент гр. 8383

\_\_\_\_\_

Киреев К.А.

Студент гр. 8383

\_\_\_\_\_

Муковский Д.В.

Преподаватель

\_\_\_\_\_

Середа А.-В.И.

Санкт-Петербург

2022

## Цель работы

Получение практических навыков нахождения точечных статистических оценок параметров распределения.

## Основные теоретические положения

Математическим ожиданием дискретной случайной величины называется сумма произведений ее возможных значений на соответствующие им вероятности:

$$M(X) = \frac{1}{N} \sum_{i=1}^n x_i n_i$$

Дисперсией случайной величины называется математическое ожидание квадрата ее отклонения от ее математического ожидания:

$$D(X) = M(X - M(X))^2$$

Среднеквадратическим отклонением случайной величины  $X$  называется квадратный корень из ее дисперсии:

$$\sigma = \sqrt{D(X)}$$

Выборочная дисперсия определяется по формуле:

$$D_B = \frac{1}{N} \sum_{i=1}^k (x_i - \bar{x})^2 n_i$$

Исправленная выборочная дисперсия определяется по формуле:

$$s^2 = \frac{N}{N-1} D_B$$

Центральным моментом порядка  $k$  случайной величины  $X$  называется математическое ожидание величины:

$$M(X - M(X))^k = m_k.$$

Асимметрией, или коэффициентом асимметрии, называется числовая характеристика, определяемая выражением:

$$A_s = \frac{m_3}{s^3},$$

где  $m_3$  – центральный эмпирический момент третьего порядка,  $s$  – исправленная выборочная дисперсия.

Эксцессом, или коэффициентом эксцесса, называется численная характеристика случайной величины, которая определяется выражением:

$$E = \frac{m_4}{s^4} - 3.$$

Мода дискретной случайной величины – это наиболее вероятное значение этой случайной величины.

$$M_o = x_o + \frac{(m_2 - m_1)}{(m_2 - m_1) + (m_2 - m_3)} h$$

Медиана случайной величины  $X$  – это такое ее значение  $M_e$ , для которого выполнено равенство

$$M_e = x_o + \frac{0,5 * n - n_{m-1}^n}{n_o} h$$

### **Постановка задачи**

Для заданных выборочных данных вычислить с использованием метода моментов и условных вариантов точечные статистические оценки математического ожидания, дисперсии, среднеквадратического отклонения, асимметрии и эксцесса исследуемой случайной величины. Полученные результаты содержательно проинтерпретировать.

### **Выполнение работы**

Для интервального ряда, полученного в лабораторной работе №1 были найдены середины интервалов и накопленные частоты. Интервальный ряд представлен в таблице 1.

Таблица 1

<b>Границы интервалов</b>	<b>Середины интервалов</b>	<b>Абсолютная частота</b>	<b>Относительная частота</b>	<b>Накопленная частота</b>
[320, 357)	338.5	5	0.048	0.048
[357, 394)	375.5	8	0.077	0.125
[394, 431)	412.5	23	0.221	0.346
[431, 468)	449.5	25	0.240	0.586
[468, 505)	486.5	24	0.231	0.817
[505, 542)	523.5	15	0.144	0.961
[542, 576)	559	4	0.039	1

Объем выборки  $n = 104$

Количество интервалов  $k = 1 + 3.31 * \lg n = 7$

Ширина интервала  $h = \frac{x_{max} - x_{min}}{k} = \frac{576 - 320}{7} = 37$

Условные варианты можно найти как  $u_j = \frac{x_j - C}{h}$ , где  $C$  – условный ноль.

Условные моменты  $k$ -го порядка:

$$\overline{M}_k^* = \frac{1}{N} \sum n_j \left( \frac{x_j - C}{h} \right)^k = \frac{1}{N} \sum n_j u_j^k$$

Результаты вычислений представлены в табл. 2.

Таблица 2

<b><math>u</math></b>	<b><math>n</math></b>	<b><math>u</math></b>	<b><math>n * u</math></b>	<b><math>n * u^2</math></b>	<b><math>n * u^3</math></b>	<b><math>n * u^4</math></b>	<b><math>n * (u + 1)^4</math></b>
338.5	0.048	-3	-0.144	0.432	-1.296	3.888	0.768
375.5	0.077	-2	-0.154	0.308	-0.616	1.232	0.077
412.5	0.221	-1	-0.221	0.221	-0.221	0.221	0.0
449.5	0.240	0	0.0	0.0	0.0	0.0	0.24
486.5	0.231	1	0.231	0.231	0.231	0.231	3.696
523.5	0.144	2	0.288	0.576	1.152	2.304	11.664
559	0.039	3	0.117	0.351	1.053	3.159	9.984
$\Sigma$	1	—	0.117	2.119	0.303	11.035	26.429

Сумма элементов последнего столбца является контрольной суммой, и так как в данном случае во втором столбце записаны относительные частоты, должно быть выполнено равенство:

$$\sum n_j * u_j^4 + 4 * \sum n_j * u_j^3 + 6 * \sum n_j * u_j^2 + 4 * \sum n_j * u_j + 1 = \sum n_j * (u_j + 1)^4$$

$$11.035 + 4 * 0.303 + 6 * 2.119 + 4 * 0.117 + 1 = 26.429$$

Эмпирические начальные и центральные моменты вычислены ниже:

$$\bar{x}_B = \overline{M}_1 = \overline{M}_1^* h + C = 453.829$$

$$D_B = \overline{m}_2 = \left( \overline{M}_2^* - (\overline{M}_1^*)^2 \right) h^2 = 2882.171$$

$$\overline{m}_3 = \left( \overline{M}_3^* - 3 \overline{M}_2^* \overline{M}_1^* + 2 (\overline{M}_1^*)^3 \right) h^3 = -22164.019$$

$$\overline{m}_4 = \left( \overline{M}_4^* - 4 \overline{M}_3^* \overline{M}_1^* + 6 \overline{M}_2^* (\overline{M}_1^*)^2 + 2 (\overline{M}_1^*)^4 \right) h^4 = 20740732.146$$

Найдем выборочное среднее и дисперсию с помощью стандартных формул.

Статистическая оценка математического ожидания:

$$\bar{x}_B = \frac{1}{N} \sum_{i=1}^k x_i n_i = 453.716$$

Статистическая оценка дисперсии:

$$D_B = \frac{1}{N} \sum_{i=1}^k (x_i - \bar{x}_B)^2 n_i = 2865.503$$

Данная статистическая оценка является смещенной оценкой, поэтому вычислим исправленную оценку дисперсии:

$$s^2 = \frac{N}{N-1} D_B = \frac{104}{103} * 2865.503 = 2893.324$$

Статистические оценки СКО:

$$\sigma_B = \sqrt{D_B} = \sqrt{2865.503} = 53.53$$

$$s = \sqrt{s^2} = \sqrt{2893.324} = 53.78$$

Статистические оценки математического ожидания и дисперсии, вычисленные по стандартным формулам и с помощью условных вариантов совпадают с небольшой погрешностью.

Статистические оценки коэффициентов асимметрии и эксцесса можно вычислить по формулам:

$$\overline{A_s} = \frac{\overline{m_3}}{s^3}$$

$$\overline{E} = \frac{\overline{m_4}}{s^4} - 3$$

Центральные эмпирические моменты третьего и четвертого порядков были найдены выше.

Статистическая оценка коэффициента асимметрии:

$$\overline{A_s} = \frac{\overline{m_3}}{s^3} = \frac{-22164.019}{53.78^3} = -0.000000915$$

Статистическая оценка коэффициента эксцесса:

$$\overline{E} = \frac{\overline{m_4}}{s^4} - 3 = \frac{20740732.146}{53.78^4} - 3 = -2.99$$

Коэффициент асимметрии отрицателен, следовательно, в данном случае это левосторонняя асимметрия, которая характеризуется удлинённым левым хвостом, а также неравенством  $\overline{x}_B < M_o$ , но полученное значение незначительно и скос распределения небольшой.

Коэффициент эксцесса также отрицателен, следовательно, эмпирическое распределение является более низким и пологим относительно нормального распределения.

Вычислим моду и медиану заданного распределения для интервального ряда.

Мода заданного распределения:

$$M_o = x_0 + \frac{n_m - n_{m-1}}{(n_m - n_{m-1}) + (n_m - n_{m+1})} h,$$

где  $n_m$  – частота модального интервала,

$n_{m-1}$  – частота предыдущего интервала,

$n_{m+1}$  – частота следующего интервала,

$x_0$  – нижняя граница модального интервала

$$M_o = 431 + 37 \frac{25 - 23}{(25 - 23) + (25 - 24)} = 455.67$$

Медиана заданного распределения:

$$M_e = x_0 + \frac{0.5n - n_{m-1}^n}{n_m} h,$$

где  $n_m$  – частота медианного интервала,

$n_{m-1}^n$  – накопленная частота предыдущего интервала,

$x_0$  – нижняя граница медианного интервала

$$M_e = 431 + \frac{0.5 * 104 - 36}{25} 37 = 454.68$$



Рисунок 1 – Гистограмма относительных частот с отмеченными модой, медианой и выборочным средним

Видно, что мода смещена относительно центра модального интервала в сторону правого интервала с большей частотой. Медиана также смещена правее, так как по правую сторону находится большее количество вариантов.

В целом можно заметить, что медиана, мода и выборочное среднее примерно равны, поэтому можно предположить, что анализируемая переменная имеет примерно нормальное распределение.

### **Выводы**

В ходе выполнения данной лабораторной работы были получены практические навыки нахождения точечных статистических оценок параметров распределения.

Для интервального ряда из лабораторной работы №1 были найдены середины интервалов и накопленные частоты, далее для полученных вариантов были вычислены условные варианты. Были вычислены условные эмпирические моменты через условные варианты, и с их помощью вычислены начальные и центральные эмпирические моменты. Корректность вычислений была проверена контрольной суммой, которая дала понять, что вычисления были верны.

Были посчитаны выборочное среднее и дисперсия с помощью стандартных формул и с помощью условных вариантов. Статистические оценки, вычисленные по стандартным формулам и с помощью условных вариантов совпали.

Была найдена статистическая оценка коэффициентов асимметрии и эксцесса. Коэффициент асимметрии получился отрицательным, то есть — это левосторонняя асимметрия, которая характеризуется удлинённым левым хвостом, а также неравенством  $\bar{x}_b < M_o$ , но полученное значение незначительно и скос распределения небольшой. Коэффициент эксцесса также отрицателен, следовательно, эмпирическое распределение является более низким и пологим относительно нормального распределения. Данные наблюдения также можно увидеть на рисунке 1.

Для интервального ряда была вычислена мода и медиана. Мода оказалась смещена относительно центра модального интервала в сторону правого интервала с большей частотой. Медиана также смещена правее, так как по правую сторону находится большее количество вариантов.



## ПРИЛОЖЕНИЕ А

### ИСХОДНЫЙ КОД

```
# %%
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from IPython.core.interactiveshell import InteractiveShell
InteractiveShell.ast_node_interactivity = "all"
pd.set_option('display.max_columns', None)
pd.set_option('display.max_rows', None)

# %%
original = pd.read_csv('c:/Users/gandh/dev/unv/smoed/me/lab1/data/data2.csv')
var_row = pd.read_csv('c:/Users/gandh/dev/unv/smoed/me/lab1/data/data4.csv')
var_row.to_csv('data/var_row.csv', index=False)
n = 104
h = 37

# %%
int_row = pd.read_csv('c:/Users/gandh/dev/unv/smoed/me/data/interval.csv')
int_row['cum_sum'] = np.round(np.cumsum(int_row['rf']), 3)
int_row['rf'] = np.round(int_row['rf'], 3)
int_row.to_csv('data/int_row.csv', index=False)

# %%
usl_mom = int_row.copy()
usl_mom = usl_mom.iloc[:, [1,3]]
usl_mom['u'] = np.arange(-3,4,1)
usl_mom['nu'] = usl_mom['rf']*usl_mom['u']
usl_mom['nu2'] = usl_mom['rf']*pow(usl_mom['u'], 2)
usl_mom['nu3'] = usl_mom['rf']*pow(usl_mom['u'], 3)
usl_mom['nu4'] = usl_mom['rf']*pow(usl_mom['u'], 4)
usl_mom['nu4+'] = usl_mom['rf']*pow(usl_mom['u']+1, 4)

# %%
usl_mom_f = usl_mom.append(usl_mom.sum(), ignore_index=True)
usl_mom_f.to_csv('data/usl_mom.csv', index=False)

# %%
```

```

moms = usl_mom_f.iloc[7, [3,4,5,6]]
moms[3]+4*moms[2]+6*moms[1]+4*moms[0]+1

# %%
int_mean = (int_row['avg_inter']*int_row['af']).sum()/n
int_var = (((int_row['avg_inter']-int_mean)**2)*int_row['af']).sum()/n
s = int_var*(n/(n-1))
std_s = np.sqrt(s)
std_var = np.sqrt(int_var)
std_s
std_var

# %%
np.mean(original, axis=0)
np.std(original, axis=0)
np.var(original, axis=0)*(n/(n-1))

# %%
M1 = moms[0]*h+449.5
m2 = (moms[1] - pow(moms[0],2))*pow(h,2)
m3 = (moms[2] - 3*moms[1]*moms[0] + 2*pow(moms[0],3))*pow(h,3)
m4 = (moms[3] - 4*moms[2]*moms[0] + 6*moms[1]*pow(moms[0],2) -
3*pow(moms[0],4))*pow(h,4)

# %%
As = m3/(pow(s, 3))
Ex = (m4/(pow(s, 4))) - 3

# %%
As, Ex

# %%
original.mean()
np.asarray(original.mode())
original.median()

# %%
raw_mode = 431+h*(2/3)
raw_median = 431+(((0.5*n)-36)/25)*h
raw_mode
raw_median
int_mean

# %%

```

```

original.head()

# %%
sns.set_theme(style="whitegrid", palette='deep', context='notebook',
font_scale=1.3)
ax = sns.displot(data=original, x='nu', bins=np.array([320, 357, 394, 431,
468, 505, 542, 576]),
kind='hist', height=8.27, aspect=11.7/8.27, stat='density')
plt.vlines(raw_mode, 0, int_row.loc[3, 'rf']/h, colors='orange', lin-
estyles='solid', label='$M_o$')
plt.vlines(raw_median, 0, int_row.loc[3, 'rf']/h, colors='r', lin-
estyles='solid', label='$M_e$')
plt.vlines(int_mean, 0, int_row.loc[3, 'rf']/h, colors='k', lin-
estyles='solid', label='$x_v$')
ax.set_axis_labels('Середина интервала', 'Частота')
ax.set(xticks=int_row['avg_inter'], yticks=round((int_row['rf']/h), 4))
ax.fig.suptitle('Гистограмма для относительных частот')
plt.legend()
plt.savefig('pics/1.png')

# %%

```